

Relatório — Laboratório Estatístico Interativo

Integrantes:

Erik (matrícula 72601771)
Marcelo S. F. (matrícula 72650096)
Nadiely (matrícula 72650083)
Ulysses (matrícula 72650533)
Valentine (matrícula 72650508)

1. Dataset escolhido e justificativa

Utilizamos um conjunto de dados sobre municípios brasileiros, contendo 5.570 registros e 8 variáveis: `municipio`, `uf`, `estado`, `regiao` (categóricas) e `populacao`, `renda_media_mensal`, `pib_anual_mil_reais`, `pib_per_capita_reais` (numéricas).

O tema foi escolhido por permitir explorar desigualdades regionais reais do Brasil (população, renda e produção econômica), com variáveis suficientes para cobrir todos os módulos exigidos: estatística descritiva, simulação, distribuições teóricas e regressão.

2. Núcleo estatístico próprio

Todas as medidas estatísticas exibidas na aplicação foram implementadas do zero no arquivo `minhastats.py`, sem uso de funções prontas de bibliotecas estatísticas. As fórmulas utilizadas, em notação matemática, foram as seguintes:

$$\text{Média: } \bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

Mediana: valor central da lista ordenada (ou média dos dois valores centrais quando n é par)

Moda: valor de maior frequência no conjunto de dados

$$\text{Variância amostral: } s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

$$\text{Desvio padrão amostral: } s = \sqrt{s^2}$$

Quartis: interpolação linear na posição $(p / 100) \times (n - 1)$ da lista ordenada

$$\text{Coeficiente de variação: } CV = (s / \bar{x}) \times 100\%$$

$$\text{Covariância amostral: } \text{cov}(x, y) = \sum (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$$

$$\text{Correlação de Pearson: } r = \text{cov}(x, y) / (s_x \times s_y)$$

$$\text{Regressão linear (mínimos quadrados): } b_1 = \text{cov}(x, y) / \text{var}(x), b_0 = \bar{y} - b_1 \times \bar{x}, \hat{y} = b_0 + b_1 x$$

Coeficiente de determinação: $R^2 = r^2$

Resultados da validação: cada função foi validada em `tests/test_minhastats.py`, comparando seus resultados com os das bibliotecas NumPy e SciPy por meio de `math.isclose()`, garantindo equivalência numérica dentro da tolerância padrão de ponto flutuante do Python. Todas as funções testadas (percentil, coeficiente de variação, moda, covariância, correlação, entre outras) retornaram resultados numericamente equivalentes aos das bibliotecas de referência.

3. Resultados e explicação por módulo

Módulo 0 e 1: Dados e núcleo estatístico

Os dados foram carregados a partir do arquivo `municipios_renda.csv` e o núcleo estatístico próprio (`minhastats.py`) foi validado com sucesso, conforme descrito na seção anterior.

Módulo 2: Estatística descritiva interativa

Para a variável `populacao`, a aplicação retornou: média de 23.925,67, mediana de 12.247,50, desvio padrão de 40.460,82, coeficiente de variação de 169,1%, amplitude de 1.158.445,00 e quartis $Q1 = 5.570,50$, $Q2 = 12.247,50$, $Q3 = 26.943,75$. A detecção de outliers pela regra do IQR identificou 493 valores atípicos (8,9% do total), e a interpretação automática apontou uma distribuição assimétrica à direita, com coeficiente de assimetria de 0,87. Na análise categórica por `regiao`, a distribuição de frequências foi: Nordeste (1.794), Sudeste (1.668), Sul (1.191), Centro-Oeste (467) e Norte (450).

Módulo 3: Probabilidade e simulação (Monte Carlo)

Na simulação da Lei dos Grandes Números, com 100 lançamentos de moeda, a frequência relativa de “cara” observada foi de 0,5400, próxima da probabilidade teórica de 0,50. Na simulação do Teorema Central do Limite, com amostras de tamanho 30 e 1.000 repetições, a distribuição das médias amostrais apresentou formato aproximadamente normal, ainda que a distribuição original da variável não seja simétrica.

Módulo 4: Distribuições teóricas

Ao ajustar uma distribuição teórica sobre o histograma da variável analisada, os parâmetros estimados a partir dos próprios dados foram μ (média) = 23.925,67 e σ (desvio padrão) = 40.460,82.

Módulo 5: Correlação e regressão linear

Ao relacionar as variáveis `populacao` (X) e `renda_media_mensal` (Y), a aplicação calculou correlação de Pearson $r = -0,0119$ e $R^2 = 0,0001$. A equação da reta obtida foi $\hat{y} = 1.425,0970 + (-0,0002) \times x$. Na predição interativa, para uma população de 23.925,67 habitantes, o modelo previu uma renda média mensal de aproximadamente 1.421,33. A aplicação exibe ainda um aviso destacando que

correlação não implica causalidade.

4. As três descobertas mais interessantes

Primeira descoberta: concentração e assimetria populacional

A população dos municípios é extremamente concentrada e assimétrica. A média de população (23.925,67) é quase o dobro da mediana (12.247,50), um forte sinal de assimetria à direita. O coeficiente de variação de 169,1% e o coeficiente de assimetria de 0,87 confirmam que a maioria dos municípios brasileiros é pequena, enquanto um grupo relativamente pequeno de grandes centros urbanos eleva a média. 493 municípios (8,9% do total) foram classificados como outliers pela regra do IQR, provavelmente capitais e regiões metropolitanas.

Histograma




Figura 1: histograma da variável populacao, gerado pela aplicação.

Segunda descoberta: concentração municipal no Nordeste

O Nordeste concentra o maior número de municípios do país: Nordeste (1.794), Sudeste (1.668), Sul (1.191), Centro-Oeste (467) e Norte (450). Isso reflete a fragmentação administrativa histórica do Nordeste; um maior número de municípios não implica maior população total ou riqueza, apenas uma divisão territorial mais pulverizada.

Gráfico de barras




Figura 2: distribuição de municípios por região, gerada pela aplicação.

Terceira descoberta: ausência de relação entre população e renda

O tamanho da população não prediz a renda média, um achado contraintuitivo. A correlação entre população e renda média mensal é praticamente nula ($r = -0,0119$; $R^2 = 0,0001$), ou seja, o modelo de regressão linear não consegue prever a renda a partir do tamanho do município. Isso contraria a intuição comum de que “cidade maior equivale a mais renda”. Como destacado pela própria aplicação, correlação não implica causalidade: outros fatores (infraestrutura, comércio, serviços) provavelmente influenciam renda e população de forma independente.

Gráfico de dispersão com reta de regressão ↗




Figura 3: dispersão e reta de regressão entre *populacao* e *renda_media_mensal*, gerada pela aplicação.

5. Conclusão

O Laboratório Estatístico Interativo permitiu não apenas calcular, mas também visualizar e interpretar padrões reais nos dados municipais brasileiros, evidenciando desigualdades de distribuição populacional, concentração regional e a ausência de relação linear direta entre porte populacional e renda média.